

Дисклеймер.

Автор не несет ответственности за любой ущерб, причиненный Вам при использовании данного документа. Автор напоминает, что данный документ может содержать ошибки и опечатки, недостоверную и/или непроверенную информацию. Если Вы желаете помочь в развитии проекта или сообщить об ошибке/опечатке/неточности:

[GitHub проекта](#)

[Автор в ВК](#)

Содержание

1	Погрешности	3
1.1	Погрешности приближенных вычислений	3
1.1.1	Погрешности арифметических действий	3
1.1.2	Обратная задача погрешности	4
1.1.3	Статистический подход	4
1.1.4	Примеры неустойчивых задач и методов	4
2	Линейные уравнения	5
2.1	Решение систем линейных уравнений	5
2.1.1	Число обусловленности	6
2.1.2	Метод Гаусса	6
2.1.3	LU-разложение	6
2.1.4	QR-разложение	6
2.1.5	Итерационные методы решения СЛАУ	8
3	Нелинейные уравнения	10
3.1	Метод половинного деления	10
3.2	Метод простой итерации	10
3.3	Метод Ньютона	10
3.4	Метод секущих	11
3.5	Модифицированный метод Ньютона	11
4	Интерполяция и приближение функций	12
4.1	Общие задачи интерполяции	12
4.2	Алгебраическое интерполирование	12
4.2.1	Интерполяционный полином Лагранжа	13
4.2.2	Погрешность интерполяционного полинома Лагранжа	13

1 Погрешности

1.1 Погрешности приближенных вычислений

- 1) Погрешность начальных данных (задачи, измерений).
- 2) Методическая погрешность.
- 3) Вычислительная погрешность.

Определение 1.1. Если a — приближенное значение, A — точное, тогда $\Delta a = |A - a|$ — абсолютная погрешность.

Определение 1.2. $\delta a = \frac{\Delta a}{|a|}$ — относительная погрешность. Она показывает, сколько верных знаков в записи числа.

Рассмотрим, как погрешности ведут себя при вычислениях.

1.1.1 Погрешности арифметических действий

$x_1 \pm \Delta x_1$ и $x_2 \pm \Delta x_2$ — неточные числа.

Тогда:

$$1) (x_1 + x_2) \pm \Delta(x_1 + x_2) = x_1 + \Delta x_1 + x_2 + \Delta x_2 \Rightarrow \Delta_+ = x_1 + x_2.$$

Таким образом, $|\Delta_{\pm}| \leq |\Delta x_1| \pm |\Delta x_2|$.

Отсюда абсолютная: $\frac{\Delta(x_1+x_2)}{x_1+x_2} = \frac{\Delta x_1}{x_1+x_2} + \frac{\Delta x_2}{x_1+x_2} \leq \delta x_1 + \delta x_2$.

Если $x_1, x_2 > 0$, то $\delta_+ \leq \max \delta x_i$.

А вот для вычитания $\frac{\Delta(x_1-x_2)}{(x_1-x_2)}$ и возникает большая проблема для относительной погрешности.

$$2) (x_1 x_2) \pm \Delta(x_1 x_2) = x_1 x_2 + x_1 \Delta x_2 + x_2 \Delta x_1 + \Delta x_1 \Delta x_2 \Rightarrow \Delta_+ \approx x_1 \Delta x_2 + x_2 \Delta x_1.$$

Отсюда абсолютная: $\frac{\Delta(x_1 x_2)}{x_1 x_2} \approx \frac{\Delta x_2}{x_2} + \frac{\Delta x_1}{x_1} \Rightarrow |\delta| \leq |\delta x_1| + |\delta x_2|$.

Пусть $f(\bar{x}_1, \dots, \bar{x}_n)$, где $\bar{x}_1 = x_1 + \Delta x_1, \dots, \bar{x}_n = x_n + \Delta x_n$.

Посчитаем

$$\Delta f = f(x_1, \dots, x_n) - f(\bar{x}_1, \dots, \bar{x}_n) = \left[\frac{\partial f}{\partial x_1}(x_1, \dots, x_n) \Delta x_1 + \dots + \frac{\partial f}{\partial x_n}(x_1, \dots, x_n) \Delta x_n \right] + o((\Delta x)^2)$$

откуда абсолютная погрешность:

$$|\Delta f| \leq \sum_{i=1}^n \left| \frac{\partial f}{\partial x_i} \right| |\Delta x_i|$$

Рассмотрим относительную:

$$\frac{\Delta f}{f} = \delta f = \sum_{i=1}^n \left| \frac{\partial f}{\partial x_i} \cdot \frac{1}{f} \right| |\Delta x_i| = \sum_{i=1}^n \left| \frac{\partial \ln f}{\partial x_i} \Delta x_i \right|$$

где $\frac{\partial \ln f}{\partial x_i} = \frac{\partial f}{f \partial x_i}$.

Отсюда $\ln(x_1 \cdot \dots \cdot x_n) = \ln x_1 + \dots + \ln x_n \Rightarrow \frac{\partial \ln(x_1 \cdot \dots \cdot x_n)}{\partial x_i} = \frac{1}{x_i}$.

То есть для деления $|\delta_{\div}| \leq |\delta x_1| + |\delta x_2|$.

1.1.2 Обратная задача погрешности

Проблема. По требуемой на Δf (δf) найти допустимые Δx (δx).

Пример 1.1.

1) Принцип равных влияний: считаем, что вклад всех слагаемых в погрешность одинаков:

$$\left| \frac{\partial f}{\partial x_1} \right| \cdot \Delta x_1 = \left| \frac{\partial f}{\partial x_2} \right| \cdot \Delta x_2 = \dots = \text{const}$$

Откуда

$$\Delta x_i \leq \frac{|\Delta f|}{n \left| \frac{\partial f}{\partial x_i} \right|}$$

2) Принцип равных погрешностей: требуем одинаковых Δx_i :

$$\Delta x_1 = \Delta x_2 = \dots = \text{const} = \Delta x$$

Откуда

$$|\Delta x| \leq \frac{|\Delta f|}{\sum_{i=1}^n \left| \frac{\partial f}{\partial x_i} \right|}$$

1.1.3 Статистический подход

$\Delta S_n \div \sqrt{n}$, где S_n — сумма n слагаемых ($n > 10$).

Тогда $\Delta S_n \approx \sqrt{3n} \cdot 0.5 \cdot 10^{-m}$ если $\Delta x_i \leq 0.5 \cdot 10^{-m}$.

Таким образом, при статистическом подходе погрешность $\frac{\Delta S_n}{n} \rightarrow 0$ $n \rightarrow \infty$.

1.1.4 Примеры неустойчивых задач и методов

1) Требуется решить $(x - a)^n = \varepsilon$, где a, n, ε — заданные числа, при этом $n \gg 1$, $n \in \mathbb{N}$, $0 < \varepsilon < 1$

$x = a$ — приближенное.

$\Delta x = \sqrt[n]{\varepsilon}$ если $\varepsilon \approx 10^{-16}$, $n \approx 10$, $\Delta x \approx 10^{-2}$.

2) $(x - 1)(x - 2) \dots (x - 20)$ — полином. Раскроем: $x^{20} - 210x^{19} + \dots + 20!$. А вот если мы получили погрешность округления вида $210 + 10^{-7}$. Тогда корни этого полинома не просто изменятся, но будут иметь вид:

$$x = 1.000$$

\vdots

$$x_7 = 7.000$$

$$x_8 = 8.007$$

$$x_9 = 8.897$$

$$x_{10,19} \in \mathbb{C}$$

$$x_{20} = 20.847$$

3) Линейная система:

$$\begin{cases} x + 10y = 11 \\ 100x + 1001y = 1101 \end{cases}$$

Решение очевидно: $x = 1, y = 1$.

Добавим погрешность:

$$\begin{cases} x + 10y = 11.01 \\ 100x + 1001y = 1101 \end{cases}$$

Решение получилось: $x = 11.01, y = 0$.

4) Вычислить набор интегралов

$$\frac{1}{e} \int_0^1 x^n e^x dx$$

где $n = 0, 1, \dots$

Пусть I_n — этот интеграл. Тогда запишем рекуррентную формулу:

$$I_n = 1 - nI_{n-1}, \quad I_0 = 1 - \frac{1}{e}$$

На старых машинах при $n = 14$ уже получались неверные ответы.

Альтернатива: перевернуть формулу и записать ее в виде

$$I_{n-1} = \frac{1}{n}(1 - I_n)$$

2 Линейные уравнения

2.1 Решение систем линейных уравнений

Определение 2.1. Норма: $\|\cdot\|$;

- 1) $\|x\| \geq 0, \|x\| = 0 \Leftrightarrow x = 0$;
- 2) $\|\lambda x\| = |\lambda| \cdot \|x\|$;
- 3) $\|x + y\| \leq \|x\| + \|y\|$;

Пример 2.1. Нормы векторов

$\|x\|_2 = \sqrt{x_1^2 + \dots + x_n^2}$ — долгая и неблагодарная норма;

$\|x\|_1 = |x_1| + \dots + |x_n|$ — более простая норма;

$\|x\|_p = (|x_1|^p + \dots + |x_n|^p)^{1/p}$ — строгая математическая норма;

$\|x\|_\infty = \max_{i=\overline{1,n}} |x_i|$ — наиболее частоиспользуемая норма.

Все эти нормы эквивалентны, то есть $\|\cdot\|_\alpha, \|\cdot\|_\beta$ эквивалентны, если $\exists c_1, c_2: \forall x$ выполняется $c_1 \|x\|_\beta \leq \|x\|_\alpha \leq c_2 \|x\|_\beta$.

Определение 2.2. Рассмотрим линейный оператор A ; здесь $\|Ax\| \leq C$. Тогда $\min_x C = \|A\|$ — норма матрицы, согласованная с нормой вектора, если $\|Ax\| \leq \|A\| \|x\|$.

Определение 2.3. Норма матрицы, подчиненная норме вектора:

$$\|A\| = \sup_{x \neq 0} \frac{\|Ax\|}{\|x\|} = \sup_{\|x\|=1} \|Ax\|$$

Пример 2.2.

$$1) \|A\|_1 = \max_{j=\overline{1,n}} \sum_{i=1}^n |a_{ij}|;$$

$$2) \|A\|_2 = \sqrt{\max_{i=\overline{1,n}} \lambda(A^T A)};$$

$$3) \|A\|_\infty = \max_{i=\overline{1,n}} \sum_{j=1}^n |a_{ij}|.$$

Норма Фробениуса: $\|A\|_F = \sqrt{\sum_{ij} a_{ij}^2}$.

2.1.1 Число обусловленности

Рассмотрим систему $Ax = b$ и пусть $b + \Delta b$. Как Δb повлияет на Δx ?

$A(x + \Delta x) = b + \Delta b$; $A\Delta x = \Delta b$.

$\|A\Delta x\| = \|\Delta b\|$, раскрыв скобки, $\|A\| \|\Delta x\| \geq \|\Delta b\|$;

Откуда $\|\Delta x\| \leq \|A^{-1}\| \cdot \|\Delta b\|$. Но это абсолютная погрешность. Что с относительной?

$$\frac{\|\Delta x\|}{\|x\|} \leq \frac{\|A^{-1}\| \|A\| \|\Delta b\|}{\|b\|}$$

и тогда $\nu(A) = \|A^{-1}\| \|A\|$ — число обусловленности системы.

И если $\nu(A) \gg 1$, то система плохо обусловлена.

Есть способы т.н. предобусловливания систем, однако мы их смотреть пока не будем.

Пример плохо обусловленной системы:

$$\begin{pmatrix} 1 & 10 \\ 100 & 1001 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} 11 \\ 11.01 \end{pmatrix}$$

2.1.2 Метод Гаусса

Обычный метод Гаусса.

2.1.3 LU-разложение

$A = LU$, где L — нижнетреугольная матрица, а U — верхнетреугольная. Потребуем, чтобы на главной диагонали L стояли единицы для однозначного разложения.

U — матрица, получающаяся в ходе прямого разложения Гаусса. L получается, как матрица, в которой запомнены коэффициенты, на которые мы домножали: $\frac{a_{21}}{a_{11}}$, к примеру. Но если наше разложение наткнется на ноль на диагонали, будет больно.

Поэтому используют $A = P^{-1}LU$, где P — матрица перестановки с аналогичными желаемым перестановками.

Для решения уравнения будем использовать $PAx = Pb$. Затем $Ly = Pb$.

Как ее построить? Если мы переставляли строки в исходной матрице, то аналогично должны переставить в матрице P . Затем воспользуемся тем, что P ортогональна: $P^{-1} = P^T$.

2.1.4 QR-разложение

Метод вращений Гивенса:

Строим $QR = A$, где R — верхнетреугольная матрица, а Q — ортонормированная.

Повернем A_1 на какой-то угол, чтобы получилось $\begin{pmatrix} a_{11}^{(0)} \\ 0 \\ a_{31}^{(0)} \\ \vdots \\ a_{n1}^{(0)} \end{pmatrix}$. Матрицы поворота выгля-

дят так: $\begin{pmatrix} \cos \alpha & -\sin \alpha \\ \sin \alpha & \cos \alpha \end{pmatrix}$. Матрица обратного поворота, аналогично, $\begin{pmatrix} \cos \alpha & \sin \alpha \\ -\sin \alpha & \cos \alpha \end{pmatrix}$.

Теперь, если мы домножим на матрицу $Q_{21} = \begin{pmatrix} \cos \alpha & -\sin \alpha & 0 & 0 \\ \sin \alpha & \cos \alpha & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{pmatrix}$. Тогда обнулится

элемент a_{21} . Аналогично, далее используем матрицу $Q_{31} = \begin{pmatrix} \cos \alpha & 0 & -\sin \alpha & 0 \\ 0 & 1 & 0 & 0 \\ \sin \alpha & 0 & \cos \alpha & 0 \\ 0 & 0 & 0 & 1 \end{pmatrix}$ и так

далее. Таким образом, $Q_{n,n-1}Q_{n,n-2}, \dots, Q_{21}$.

Это разложение нам понадобится для решения уравнения вида $Ax = b$ решая уравнение $Rx = Qb$.

Как найти α ? У нас есть a_{11} и a_{21} и мы именно этот вектор хотим домножить на матрицу вращения. Уравнение:

$$\begin{pmatrix} \cos \alpha & -\sin \alpha \\ \sin \alpha & \cos \alpha \end{pmatrix} \cdot \begin{pmatrix} a_{11} \\ a_{21} \end{pmatrix} = \begin{pmatrix} a_{11}^{(1)} \\ 0 \end{pmatrix}$$

Легко выводится, что $\begin{cases} \sin \alpha a_{11} + \cos \alpha a_{21} = 0 \\ \sin^2 \alpha + \cos^2 \alpha = 1 \end{cases}$, $\sin \alpha = -\frac{\cos \alpha a_{21}}{a_{11}}$, $\cos^2 \alpha + \cos^2 \alpha \left(\frac{a_{21}}{a_{11}}\right) = 1$, откуда $\cos^2 \alpha = \frac{a_{11}^2}{a_{11}^2 + a_{21}^2}$, отсюда $\cos \alpha = \frac{a_{11}}{\sqrt{a_{11}^2 + a_{21}^2}}$, $\sin \alpha = -\frac{a_{21}}{\sqrt{a_{11}^2 + a_{21}^2}}$.

Плюсы в сравнении с методом Гаусса: не нужно выбирать ведущий элемент и не растёт вычислительная погрешность. Из минусов: работает в 4 раза медленнее.

Метод отражений Хаусхольдера:

Рассмотрим вспомогательный вектор ω — вектор единичной длины. $\omega^T \omega = 1$.

Рассмотрим $U = E - 2\omega\omega^T$, $U^T U = E - 4\omega\omega^T + 4\underbrace{\omega\omega^T\omega\omega^T}_1 = E \Rightarrow U^{-1} = U^T$.

$U_\omega = (E - 2\omega\omega^T)\omega = \omega - 2\omega = -\omega \Rightarrow \omega$ — собственный вектор с собственным числом -1 .

$v \perp \omega$, то есть $v^T \omega = 0$ или $\omega^T v = 0$, $U_v = (E - 2\omega\omega^T)v = v - 2\omega\omega^T v = v \Rightarrow v$ — собственный вектор с собственным числом 1 .

Таким образом, $y = v + \alpha\omega \Rightarrow Uy = v - \alpha\omega$, то есть матрица U отражает вектор.

Пусть y, z — ... векторы. Нам нужно найти U , такую, что $Uy = \alpha z$. Смотрим:

$$\|Uy\| = \|y\| = \|\alpha z\| \Rightarrow \alpha = \frac{\|y\|}{\|z\|}$$

$$\omega = \frac{y - \alpha z}{\|y - \alpha z\|}$$

Теперь, используя A_1 как y , e_1 как z , строим $U_1 = E - 2\omega\omega^T$. Тогда $U_1 A$ будет иметь нулевой первый столбец (исключая элемент $a_{11}^{(1)}$).

Тогда $Q = U_{n-1} \cdot \dots \cdot U_1$.

Тогда решением $Ax = b$ будет являться $Rx = Q^T b$.

Симметричная матрица — метод квадратного корня.

$A = S^T S$, где S — верхнетреугольная. Такое разложение возможно и единственно только для симметричной матрицы.

Рассмотрим A — положительно определенная матрица, следовательно, $s_{ij} \in \mathbb{R}$. Просто расписав матрицы, получим $s_{11}^2 = a_{11}$, $s_{11}s_{12} = a_{12}$, ..., $s_{11}s_{1n} = a_{1n}$. Теперь посмотрим на вторую строку: $s_{22}^2 + s_{12}^2 = a_{22}$, $s_{23}s_{22} + s_{12}s_{13} = a_{23}$ и так далее.

Метод квадратного корня требует в 2 раза меньше операций, чем в методе Гаусса + $n\sqrt{\cdot}$.

2.1.5 Итерационные методы решения СЛАУ

Это методы, в которых мы находим начальное приближение к решению и, итерируя, уточняем его.

Рассматриваемая нами система $Ax = b$ путем неких изменений может быть приведена к форме $x = Bx + c$. И задача нахождения x становится задачей нахождения неподвижной точки.

Допустим, мы преобразовали наше уравнение ко второму виду. Теперь мы строим итератор:

$$x^{(k+1)} = Bx^{(k)} + c$$

Интуитивно понятно, что $\|B\| > 1$ влечет $\|x_k\| \rightarrow \infty$.

Лемма 2.1. Все собственные числа матрицы B по модулю меньше единицы тогда и только тогда, когда

- 1) $B^k \rightarrow_{k \rightarrow \infty} 0$;
- 2) $\exists (I - B)^{-1} = (I + B + B^2 + \dots + B^k + \dots)$;

Лемма 2.2. Если $\|B\| \leq q < 1$, то $(I - B)^{-1}$ существует, равна $\sum_{i=0}^{\infty} B^i$ и $\|(I - B)^{-1}\| \leq \frac{1}{1-q}$.

Доказательство. $\|B\| \leq q < 1 \Rightarrow \|I + B + \dots + B^k + \dots\| \leq \|I\| + \|B\| + \dots + \|B^k\| + \dots \leq \|I\| + \|B\| + \dots + \|B\|^k + \dots \leq 1 + q + \dots + q^k + \dots = \frac{1}{1-q}$, следовательно, существует $V = \sum_{k=0}^{\infty} B^k$, такое, что $\|V\| \leq \frac{1}{1-q}$.

Тогда $(I - B)V = IV - BV = I + B + B^2 + \dots + B^k + \dots - B - B^2 - \dots - B^k - \dots = I$, следовательно $\|(I - B)^{-1}\| \leq \frac{1}{1-q}$. \square

Теорема 2.1. Необходимым и достаточным условием сходимости метода простой итерации с любым начальным приближением $x^{(0)}$ к x^* : $x^* = Bx^* + c$ является ограниченность собственных чисел матрицы B числом, меньшим единицы.

Доказательство.

Достаточность:

$$x^{(1)} = Bx^{(0)} + c$$

$$x^{(2)} = B(Bx^{(0)} + c) + c = B^2x^{(0)} + Bc + c$$

....

$$x^{(k)} = B^kx^{(0)} + (B^{(k-1)} + \dots + I)c$$

Из условий 1) $B^k \rightarrow_{k \rightarrow \infty} 0$; 2) $\exists (I - B)^{-1} = \sum_{i=0}^{\infty} B^i$ следует, что при $k \rightarrow \infty$ выполняется $x^{(k)} \rightarrow (I - B)^{-1}c$.

Преобразуем $x = Bx + c \Leftrightarrow (I - B)x = c$, следовательно, $(I - B)^{-1}c$ является решением.

Пусть $\exists x^{**}$ — другое решение. Тогда $x^* = Bx^* + c$, $x^{**} = Bx^{**} + c$ и $x^* - x^{**} = B(x^* - x^{**})$, следовательно, $\lambda = 1$ является собственным числом B с собственным вектором $x^* - x^{**}$, а это противоречие.

Необходимость:

$x^{(k)} \rightarrow_{k \rightarrow \infty} x^* \Rightarrow I + B + \dots + B^k + \dots = V$, V — конечная матрица и $V = (I - B)^{-1}$. Тогда $x^* = \lim_{k \rightarrow \infty} B^kx^{(0)} + (I - B)^{-1}c$, подставив в уравнение, получим $(I - B)x^* = c$, откуда $(I - B)(I - B)^{-1}c + (I - B)\lim_{k \rightarrow \infty} B^kx^{(0)} = c$ следовательно, $\lim_{k \rightarrow \infty} B^k$, следовательно, собственные числа матрицы равны ??? \square

Теорема 2.2. Пусть $\|B\| \leq q < 1$, тогда МПИ сходится $\forall x^{(0)}$ к $x^* : x^* = Bx^* + c$ и верны следующие оценки:

- 1) $\|x^* - x^{(k)}\| \leq \frac{q}{1-q} \|x^{(k)} - x^{(k-1)}\|$ — апостериорная оценка;
- 2) $\|x^* - x^{(k)}\| \leq \frac{q^k}{1-q} \|x^{(1)} - x^{(0)}\|$ — априорная оценка.

Доказательство. $x^{(k-1)} - x^{(k)} = Bx^{(k)} + c - Bx^{(k-1)} + c = B(x^{(k)} - x^{(k-1)}) \Rightarrow \|x^{(k+1)} - x^{(k)}\| \leq q \|x^{(k)} - x^{(k-1)}\|$

$$\|x^{(k+m)} - x^{(k)}\| \leq \|x^{(k+m)} - x^{(k+m-1)} + \dots + x^{(k+1)} - x^{(k)}\| \leq \|x^{(k+m)} - x^{(k+m-1)}\| + \dots + \|x^{(k+1)} - x^{(k)}\| \leq (q^{m-1} + q^{m-2} + \dots + q + 1) \|x^{(k+1)} - x^{(k)}\| = \frac{1-q^m}{1-q} \|x^{(k+1)} - x^{(k)}\|$$

$$\text{Тогда } \|x^* - x^{(k)}\| \leq \frac{1}{1-q} \|x^{(k+1)} - x^{(k)}\| \leq \frac{q}{1-q} \|x^{(k)} - x^{(k-1)}\|.$$

Применив много раз, получим $\|x^{(k+1)} - x^{(k)}\| \leq q^2 \|x^{(k-1)} - x^{(k-2)}\|, \dots, \|x^{(k+1)} - x^{(k)}\| \leq q^k \|x^{(1)} - x^{(0)}\|$. Таким образом, при $k \rightarrow \infty$ последовательность сходится в себе, \mathbb{R}^n полное, следовательно, существует $x^* = \lim_{k \rightarrow \infty} x^{(k)}$.

$$(I - B)(B^k x^{(0)} + (I - B)^{-1}c) = c, B^k x^{(0)} = 0, \text{ так как } \|B\| \leq q \Rightarrow \|B^k\| \leq q^k.$$

$$\text{И в результате } \|x^* - x^{(k)}\| \leq \frac{q}{1-q} \|x^{(k)} - x^{(k-1)}\| \quad \square$$

Замечание 2.1. Апостериорная оценка точнее, чем априорная.

Замечание 2.2. Другая априорная оценка: $x^* = (I - B)^{-1}c = (I + B + \dots + B^k + \dots)c$, соответственно, $x^{(k)} = B^k x^{(0)} + (I + \dots + B^k)c$. Тогда $x^* - x^{(k)} = B^k x^{(0)} + (B^k + B^{k-1} + \dots)c$. Если взять норму: $\|x^* - x^{(k)}\| \leq q^k \|x^{(0)}\| + q^k \|(I - B)^{-1}\|c \leq q^k \left(\|x^{(0)}\| + \frac{\|c\|}{1-q} \right)$. Кажется, так.

Замечание 2.3. Как выбрать $x^{(0)}$?

Метод Якоби:

$$Ax = b.$$

Берем матрицу и делим каждую из ее строк на диагональный элемент в этой строке. Мы в каждой строке получим x с соответствующим номером с единичным коэффициентом.

$$x_1 = -\frac{a_{12}}{a_{11}}x_2 - \dots - \frac{a_{1m}}{a_{11}}x_m + \frac{b_1}{a_{11}}$$

$$x_2 = -\frac{a_{21}}{a_{22}}x_1 - \frac{a_{23}}{a_{22}}x_3 \dots - \frac{a_{2m}}{a_{22}}x_m + \frac{b_2}{a_{22}}$$

и так далее. Теперь матрица B будет иметь нули на диагонали. Соответственно, метод Якоби есть МПИ в такой системе.

Теорема 2.3. Для матрицы с диагональным преобладанием метод Якоби сходится.

Определение 2.4. Матрица с диагональным преобладанием — матрица, такая, что

$$\forall i = \overline{1, n} : |a_{ii}| > \sum_{j=1, j \neq i}^n |a_{ij}|$$

$$\delta = \min_{i=\overline{1, n}} \left(|a_{ii}| - \sum_0 |a_{ij}| \right)$$

— величина диагонального преобладания. Чем больше, тем быстрее матрица сойдется.

Теорема 2.4. Метод Якоби сходится тогда и только тогда, когда все корни уравнения

$$\det \begin{pmatrix} \lambda a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & \lambda a_{22} & \dots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \dots & \lambda a_{nn} \end{pmatrix}$$

Метод Зейделя:

Когда мы применяем метод простой итерации, мы строим $x_1^{(k+1)} = b_{11}x_1^{(k)} + b_{12}x^{(k)} + \dots + b_{1n}x_n^{(k)} + c_1$. Остальное аналогично с другими строками.

3 Нелинейные уравнения

$f(x) = 0$ — поиск корней нелинейной функции.

3.1 Метод половинного деления

Рассматриваем отрезок $[a, b]$, на котором есть корни, то есть $f(a)f(b) < 0$. Вычисляем $c = \frac{a+b}{2}$, $f(c)$ и сравниваем:

1) $f(a) - f(c) < 0 \Rightarrow b := c$, $f(b) := f(c)$ и рекуррентно выполняем.

2) $f(a) - f(c) > 0$. Все то же самое, но наоборот.

3) $f(a)f(c) = 0$ — вернуть c .

Делаем, пока $\frac{b-a}{2} > \varepsilon$.

3.2 Метод простой итерации

Переформулируем $f(x) = 0$ в $x = S(x)$ и выбрав x_0 будем искать неподвижную точку: $x_{k+1} = S(x_k)$.

Например, $S(x) = x - \tau(x) - f(x)$, $\tau(x) \neq 0$ в окрестности x^* . Если $\tau(x) \equiv \tau \neq 0$ $S(x) = x - \tau f(x)$.

Теорема 3.1. Если $f(x)$ липшицова с $q \in (0, 1)$ на отрезке $V_r(a)$ и $|S(a) - a| \leq (1-q)r$, то уравнение $x = S(x)$ имеет на $V_r(a)$ единственное решение x^* , МПИ сходится $\forall x_0 \in V_r(x)$ и $|x^* - x_k| \leq q^k |x^* - x_0|$.

Если $S(x)$ непрерывно дифференцируема на отрезке и $|S'(x)| \leq q < 1$ и выполнено условие $|S(a) - a| \leq (1-q)r$, то решение существует и $\forall x_0$ метод простой итерации сходится.

3.3 Метод Ньютона

$f(x) = 0$.

Разложим функцию $f(x^*)$ в ряд по $(x_k - x^*)$. x_k — приближение к решению.

$$f(x^*) = f(x_k) + f'(x_k)(x^* - x_k) + f''(x_k) \frac{(x^* - x_k)^2}{2} + \dots$$

отсюда

$$x^* \approx x_k - \frac{f(x_k)}{f'(x_k)} = x_{k+1}$$

$x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)}$, то есть $S(x) = \frac{f(x)}{f'(x)}$, если $|S'(x)| \leq q \leq 1$ в некоторой окрестности, то МПИ сходится.

$$S'(x) = -\frac{(f'(x))^2 - f(x)f''(x)}{(f'(x))^2} + 1$$

то есть $S'(x) = \frac{f(x)f'(x)}{(f'(x))^2}$. Таким образом,

$$\left| \frac{f(x)f''(x)}{(f'(x))^2} \right| < 1$$

то есть МПИ сходится в некоторой окрестности x^* .

Оценим скорость сходимости:

$$f(x_k) + f'(x_k)(x^* - x_k) = F(x_k)$$

$$F(x) = f(x) + f'(x)(x^* - x); \quad F(x^*) = 0$$

$$F(x_k) = F(x^*) + \int_{x^*}^{x_k} F'(x) dx$$

$$F'(x) = f'(x) + f''(x)(x^* - x) + f'(x)(-1) = f''(x)(x^* - x)$$

$$F(x_k) = \int_{x^*}^{x_k} f''(x)(x^* - x) dx = f''(\xi) \int_{x^*}^{x_k} (x^* - x) dx = f''(\xi) \frac{(x^* - x_k)^2}{2}$$

$$x^* - x_{k+1} = x^* - x_k + \frac{f(x_k)}{f'(x_k)}$$

$$f'(x)(x^* - x_{k+1}) = F(x_k)$$

$$|x^* - x_{k+1}| \leq \frac{M_2}{f'(x_k)} |x^* - x_k|^2$$

таким образом,

$$|x^* - x_{k+1}| \leq \frac{q^{2^{(k+1)}-1}}{1-q} |x^* - x_0|$$

Теорема 3.2. Если на отрезке $[a, b]$ существует корень, $f'(x) \neq 0$ на $[a, b]$ и $f''(x) \neq 0$, то метод Ньютона сходится $\forall x_0$, такого, что $f(x_0)f''(x_0) > 0$.

Метод Ньютона имеет так называемую квадратичную сходимость для простых корней.

3.4 Метод секущих

Применяется в случае, если не работает метод Ньютона.

//дописать про метод Ньютона

3.5 Модифицированный метод Ньютона

Фиксируем матрицу Якоби $J(x^{(m)})$ и далее используем ее (часто берут $m = 0$). Переименуем: $J(x^{(k)}) = J_k$, $F(x^{(k)}) = F_k$. Тогда метод Ньютона говорит, что $J_k \Delta x^{(k+1)} = -F_k$, а модифицированный метод Ньютона: $J_m \Delta x^{(k+1)} = -F_k$.

Сходимость модифицированного метода Ньютона линейная (геометрическая прогрессия), но экономия достигается на вычислении J_k и LU разложении.

Часто методу Ньютона задают ограничение на число итераций.

4 Интерполяция и приближение функций

4.1 Общие задачи интерполяции

$f(x)$ задана на $[a, b]$ и $f(x)$ — «сложная» или таблично задана в точках $\{\overline{x_1}, \dots, \overline{x_n}\}$. Наша задача — быстро вычислять приближение к $f(x)$ или просто $f(x)$ в $x \notin \{\overline{x_1}, \dots, \overline{x_n}\}$. Для этого f заменяется на $a_0\varphi_0 + \dots + a_n\varphi_n$, где $\varphi_0, \dots, \varphi_n$ — «простые» функции, причем $a_0\varphi_0(x_i) + \dots + a_n\varphi_n(x_i) = f(x_i)$ для некоторых $\{x_0, \dots, x_n\} \subset [a, b]$ или из $\{\overline{x_1}, \dots, \overline{x_n}\}$. Такой прием называется интерполяцией.

Интерполяционный полином $a_0\varphi_0 + \dots + a_n\varphi_n$ может быть построен для заданной точности, только если функции $\varphi_0, \dots, \varphi_n$ обладают следующими свойствами:

1) $\varphi_0, \dots, \varphi_n, \dots$ — линейно независимы, то есть любой конечный набор из них линейно независим.

2) $\varphi_0, \dots, \varphi_n, \dots$ — полная система функций в некотором рассматриваемом функциональном пространстве, то есть $\forall f \exists b_0, \dots, b_n, \dots: f = \sum_{i=0}^{\infty} b_i\varphi_i$.

Пример 4.1. Попытка приблизить $f(x) = |x|$ на $[-1, 1]$ по равноотстоящим узлам провалена, как и попытка показать нам, что это будет.

При этом существует единственный интерполяционный полином $a_0\varphi_0 + \dots + a_n\varphi_n = \varphi$, удовлетворяющий условию $\varphi(x_i) = f(x_i)$, $i = \overline{0, n}$, если все x_i различны и φ_i линейно независимы, который находится решением СЛАУ с матрицей

$$\begin{pmatrix} \varphi_0(x_0) & \varphi_1(x_0) & \cdots & \varphi_n(x_0) \\ \varphi_0(x_1) & \varphi_1(x_1) & \cdots & \varphi_n(x_1) \\ \vdots & \vdots & \ddots & \vdots \\ \varphi_0(x_n) & \varphi_1(x_n) & \cdots & \varphi_n(x_n) \end{pmatrix} \begin{pmatrix} a_0 \\ a_1 \\ \vdots \\ a_n \end{pmatrix} = \begin{pmatrix} f(x_0) \\ f(x_1) \\ \vdots \\ f(x_n) \end{pmatrix}$$

Определение 4.1. Интерполяционный процесс — последовательное приближение f по

узлам $\begin{pmatrix} x_0^{(0)} \\ x_0^{(1)} & x_1^{(1)} \\ x_0^{(2)} & x_1^{(2)} & x_2^{(2)} \\ \dots & \dots & \dots & \dots \end{pmatrix}$ с помощью полиномов (дописать). Говорят, что интерполя-

ционный полином по X для $\{\varphi_i\}$ $i = \overline{0, \infty}$ сходится на $[a, b]$ если $\forall f \exists x$: интерполяционный полином сходится и $\forall x \exists f$ не сходится (WAT).

4.2 Алгебраическое интерполирование

Основная схема: $\varphi_i = x^i$, $i = \overline{0, \infty}$.

Линейно независимы $1, x, x^2, \dots, x^n, \dots$ и

$$\begin{pmatrix} 1 & x_0 & x_0^2 & \cdots & x_0^n \\ 1 & x_1 & x_1^2 & \cdots & x_1^n \\ 1 & x_2 & x_2^2 & \cdots & x_2^n \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_n & x_n^2 & \cdots & x_n^n \end{pmatrix}$$

— определитель Вандермонда который не равен 0 для различных x_i . При этом $1, x, x^2, \dots$ полная система функций в пространстве $C_{\mathbb{R}}$.

Рассмотрим построение интерполяционного полинома степени n по $n+1$ узлу x_0, \dots, x_n и $\dots f_0, \dots, f_n$, где $f_i = f(x_i)$.

4.2.1 Интерполяционный полином Лагранжа

Будем обозначать такой полином степени n как L_n .

Итак, должно выполняться $L_n(x_i) = f(x_i)$. Представим $L_n(x) = l_i(x)f(x_i)$, где $l_i(x_j) = \begin{cases} 1 & i = j \\ 0 & i \neq j \end{cases}$ — символ Кронекера.

Для того, чтобы построить такой полином, нам нужно, чтобы у $l_i(x)$ корнями являлись $x_0, \dots, x_{i-1}, x_{i+1}, \dots, x_n$. Тогда

$$l_i(x) = \frac{(x - x_0) \dots (x - x_{i-1})(x - x_{i+1}) \dots (x - x_n)}{(x_i - x_0) \dots (x_i - x_{i-1})(x_i - x_{i+1}) \dots (x_i - x_n)}$$

Запишем более кратко:

$$l_i(x) = \prod_{j=0, j \neq i}^n \frac{(x - x_j)}{(x_i - x_j)}$$

откуда

$$L_n(x) = \sum_{i=0}^n \left(\prod_{j=0, j \neq i}^n \frac{(x - x_j)}{(x_i - x_j)} \right) f(x_i)$$

Если ввести $\omega(x)$ — угловой многочлен, который равен $\omega_n(x) = (x - x_0) \dots (x - x_{i-1})(x - x_{i+1}) \dots (x - x_n)$, то

$$l_i(x) = \frac{\omega_n(x)}{(x - x_i)\omega'_n(x_i)}$$

и тогда

$$L_n(x) = \sum_{i=0}^n \frac{f(x_i)\omega_n(x)}{(x - x_i)\omega'_n(x_i)}$$

4.2.2 Погрешность интерполяционного полинома Лагранжа

Погрешность $r_n(x) = L_n(x) - f(x)$. Рассмотрим вспомогательную функцию $\Delta(x) = r_n(x) - K\omega_n(x)$.

Выясним, чему равна $r_n(x^*)$, где $x^* \in [a, b]$ и $x^* \neq x_i$.

Потребуем, чтобы $\Delta(x^*) = 0$, то есть

$$K = \frac{r_n(x^*)}{\omega_n(x^*)}$$

$\Delta(x)$ имеет $n + 2$ корня на $[a, b]$, следовательно, по теореме Ролля $\Delta'(x)$ имеет $n + 1$ корень между $\min(x_0, x^*)$ и $\max(x_n, x^*)$. У $\Delta^{(n+1)}(x)$ существует 1 корень и он в $[a, b]$. Пусть это некоторая точка ξ . То есть $\Delta^{(n+1)}(\xi) = r_n^{(n+1)}(\xi) - K \cdot (n+1)! = -f^{(n+1)}(\xi) - K(n+1)! = 0$, отсюда $r_n(x^*) = -\frac{f^{(n+1)}(\xi)}{(n+1)!}\omega_n(x^*)$. И теперь в силу произвольности, так как x^* — любое, то

$$\Gamma_n(x) = -\frac{f^{(n+1)}(\xi)}{(n+1)!}\omega_n(x)$$